

Clasificación de Lesiones Cutáneas mediante Aprendizaje Profundo con YOLO

Alejandro Cerezo, Germán Torres y Daniil Nemchenko

December 14, 2025

Resumen

En este trabajo presentamos un sistema de clasificación de lesiones cutáneas basado en aprendizaje profundo utilizando la arquitectura YOLO (You Only Look Once). Hemos trabajado con el conjunto de datos ISIC 2019, que contiene imágenes dermatoscópicas de ocho tipos diferentes de lesiones de la piel, incluyendo melanoma, nevus, carcinoma basocelular, queratosis actínica, queratosis benigna, dermatofibroma, lesiones vasculares y carcinoma de células escamosas. Entrenamos tres variantes del modelo YOLOv8, específicamente las versiones nano, small y medium, utilizando un subconjunto de 100 imágenes por clase para entrenamiento y 10 imágenes por clase para evaluación. Nuestros resultados muestran que el modelo YOLOv8m alcanza el mejor rendimiento con un mAP50 de 0.664 y un mAP50-95 de 0.661, mientras que el modelo YOLOv8s obtiene la mayor accuracy en clasificación con 0.633. El análisis de las curvas de entrenamiento revela que nuestros modelos no presentan sobreajuste significativo y que las versiones más grandes de YOLO proporcionan mejoras graduales en el rendimiento a costa de mayor tiempo de inferencia.

1 Introducción

El cáncer de piel representa uno de los tipos de cáncer más frecuentes a nivel mundial, y la detección temprana de lesiones malignas como el melanoma resulta fundamental para mejorar el pronóstico de los pacientes. Las técnicas de aprendizaje profundo han demostrado un potencial extraordinario para asistir en el diagnóstico de lesiones cutáneas a partir de imágenes dermatoscópicas.

En este proyecto hemos trabajado con el conjunto de datos ISIC 2019, que contiene imágenes dermatoscópicas etiquetadas con ocho categorías diagnósticas diferentes. Hemos entrenado tres variantes del modelo YOLOv8 (nano, small y medium) para analizar el compromiso entre complejidad del modelo y rendimiento final.

2 Conjunto de datos y preparación

El conjunto de datos ISIC 2019 contiene imágenes dermatoscópicas de alta resolución con etiquetas diagnósticas validadas por expertos. Las ocho categorías

son: MEL (Melanoma), NV (Nevus melanocítico), BCC (Carcinoma basocelular), AK (Queratosis actínica), BKL (Queratosis benigna), DF (Dermatofibroma), VASC (Lesiones vasculares) y SCC (Carcinoma de células escamosas).

Hemos generado dos subconjuntos balanceados: 100 imágenes por clase para entrenamiento (800 total) y 10 imágenes por clase para test (80 total). Las imágenes se organizaron según la estructura requerida por YOLO, con archivos de anotación que contienen las coordenadas del bounding box centrado cubriendo el 80% del área de la imagen.

3 Arquitectura YOLO y modelos utilizados

YOLO (You Only Look Once) es una arquitectura de redes neuronales convolucionales diseñada para detección de objetos en tiempo real. Hemos utilizado YOLOv8, que se compone de tres bloques principales: backbone (extracción de características), neck (combinación multiescala) y head (predicción de bounding boxes y clases).

Hemos entrenado tres variantes de YOLOv8: nano (3M parámetros, 8.1 GFLOPs), small (11M parámetros, 28.5 GFLOPs) y medium (26M parámetros, 78.7 GFLOPs). Utilizamos modelos pre-entrenados en COCO como punto de partida mediante transfer learning.

4 Entrenamiento de los modelos

El entrenamiento se realizó con la biblioteca Ultralytics usando 100 épocas máximo y early stopping (paciencia de 25 épocas). Los parámetros fueron: imágenes 640x640 píxeles, batch size 16, optimizador AdamW (lr=0.002) y data augmentation (rotaciones, escala, brillo, saturación y volteo horizontal).

La Figura 1 muestra las curvas de entrenamiento para el modelo YOLOv8n. Las pérdidas disminuyen consistentemente sin divergencia significativa entre train y validación, indicando ausencia de sobreajuste severo. El mAP50 y mAP50-95 aumentan progresivamente hasta estabilizarse alrededor de 0.6.




Figura 1: Métricas de entrenamiento del modelo YOLOv8n. Se observa una disminución consistente de las funciones de pérdida y un incremento gradual de las métricas de evaluación a lo largo de las épocas de entrenamiento.

La Figura 2 presenta las métricas del modelo YOLOv8s, que muestra convergencia más rápida y pérdida de clasificación más pronunciada, completando 85 épocas antes del early stopping.




Figura2: Métricas de entrenamiento del modelo YOLOv8s. El modelo presenta una convergencia similar al YOLOv8n pero con valores finales de mAP ligeramente superiores.

La Figura 3 ilustra el entrenamiento del modelo YOLOv8m, que presenta mayor variabilidad inicial pero alcanza los mejores valores de mAP entre los tres modelos.




Figura 3: Métricas de entrenamiento del modelo YOLOv8m. A pesar de mostrar mayor variabilidad inicial, este modelo alcanza los mejores valores finales de mAP.

La Figura 4 compara los tres modelos. Todos convergen hacia valores similares de box loss, mientras que el YOLOv8m alcanza los valores más altos de mAP50 a partir de la época 60.




Figura 4: Comparación entre los tres modelos YOLO durante el entrenamiento. Se muestra la evolución de la pérdida de validación y el mAP50 a lo largo de las épocas.

5 Evaluación y resultados

La Tabla 1 resume las métricas de rendimiento obtenidas por cada modelo en el conjunto de test.

Tabla 1: Comparativa de métricas de rendimiento para los tres modelos YOLO entrenados.

Modelo	mAP50	mAP50-95	Precision	Recall	Accuracy
YOLOv8n	0.608	0.594	0.509	0.652	0.507
YOLOv8s	0.650	0.636	0.550	0.634	0.633
YOLOv8m	0.664	0.661	0.563	0.647	0.582

El modelo YOLOv8m obtiene los mejores valores en mAP50 (0.664), mAP50-95 (0.661) y Precision (0.563). El YOLOv8n alcanza el mejor Recall (0.652), mientras que el YOLOv8s obtiene la mejor Accuracy (0.633). La mejora de nano a small es del 7%, mientras que de small a medium es solo del 2%.

La Figura 5 muestra las matrices de confusión para cada uno de nuestros tres modelos. Estas matrices nos permiten visualizar qué tipos de errores comete cada modelo y cuáles son las clases más difíciles de clasificar correctamente.




Figura5: Matrices de confusión para los tres modelos YOLO. Cada celda muestra el número de imágenes de la clase real (eje Y) que fueron clasificadas como la clase predicha (eje X).

El análisis de las matrices de confusión revela varios patrones interesantes sobre el comportamiento de nuestros modelos. Las clases VASC (lesiones vasculares) y DF (dermatofibroma) presentan mayor facilidad de clasificación, mientras que MEL (melanoma), NV (nevus) y BCC (carcinoma basocelular) muestran mayor confusión entre sí debido a sus características morfológicas similares.




Figura 6: Mapa de calor comparativo del rendimiento (mAP50) de los tres modelos por clase. Los colores más cálidos (rojo-amarillo) indican mejor rendimiento.

La Figura 6 muestra el mapa de calor comparativo del rendimiento de los modelos para cada clase, donde podemos visualizar de forma clara las diferencias en la capacidad de clasificación según el tipo de lesión.

6 Análisis del comportamiento durante el entrenamiento

Las curvas de entrenamiento muestran que las pérdidas de entrenamiento y validación disminuyen de forma paralela sin divergencia, indicando ausencia de sobreajuste significativo. Los valores finales de mAP (0.60-0.66) sugieren margen de mejora mediante mayor cantidad de datos o data augmentation más agresivo. El early stopping funcionó correctamente, deteniendo el entrenamiento cuando no se observaron mejoras significativas.

7 Conclusiones

Hemos desarrollado y evaluado un sistema de clasificación de lesiones cutáneas utilizando YOLOv8 con el conjunto de datos ISIC 2019. Los resultados muestran que el modelo YOLOv8m alcanza un mAP50 de 0.664, mientras que el YOLOv8s obtiene la mejor accuracy (0.633).

Las curvas de entrenamiento confirman ausencia de sobreajuste significativo. El análisis de matrices de confusión revela que las lesiones vasculares y dermatofibroma son clasificadas con alta precisión, mientras que melanoma, nevus y carcinoma basocelular presentan mayor confusión.

Como trabajo futuro, se propone aumentar el tamaño del conjunto de entrenamiento e incorporar información clínica adicional. Los resultados demuestran el potencial del aprendizaje profundo para asistir en el diagnóstico, aunque estos sistemas deben considerarse herramientas de apoyo y no sustitutos del criterio médico.

Referencias

1. Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8*. <https://github.com/ultralytics/ultralytics>
2. Combalia, M., et al. (2019). *BCN20000: Dermoscopic Lesions in the Wild*. arXiv preprint arXiv:1908.02288.
3. Tschandl, P., Rosendahl, C., & Kittler, H. (2018). *The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions*. Scientific Data, 5, 180161.
4. Esteva, A., et al. (2017). *Dermatologist-level classification of skin cancer with deep neural networks*. Nature, 542(7639), 115-118.